

Diseño del Modelo Dimensional del Data Warehouse

1.Introducción.

En esta sección se describe el diseño del modelo dimensional del Data Warehouse propuesto para el análisis de un sistema de comercio electrónico, basado en el Brazilian E-Commerce Public Dataset (Olist). El objetivo principal del modelo es facilitar el análisis de ventas, comportamiento de clientes y métodos de pago, manteniendo un equilibrio entre simplicidad, realismo y viabilidad dentro del contexto de un Trabajo Fin de Grado.

2.Metodología de diseño: enfoque Kimball.

El diseño del Data Warehouse se ha realizado siguiendo la metodología propuesta por Ralph Kimball, basada en un enfoque bottom-up y orientada al análisis de negocio. Esta metodología se centra en el uso de modelos dimensionales, compuestos por tablas de hechos y dimensiones, con el objetivo de facilitar la consulta, comprensión y explotación analítica de datos.

Entre los principios clave de Kimball aplicados en este proyecto destacan:

- La definición explícita de la granularidad de cada tabla de hechos.
- El uso de esquemas en estrella para simplificar las consultas analíticas.
- La separación entre hechos (eventos medibles) y dimensiones (contexto descriptivo)

Este enfoque permite construir un modelo flexible, fácilmente ampliable y orientado a la toma de decisiones.

3.Alcance y selección de datos.

A partir del dataset original, se ha realizado una selección consciente de los ficheros a utilizar, priorizando aquellos que aportan mayor valor analítico:

CSV utilizados:

- Olist_orders_dataset.csv
- Olist_order_items_dataset.csv
- Olist_customers_dataset.csv
- Olist_products_dataset.csv
- Olist_order_payment_dataset.csv
- Product_category_name_translation.csv

CSV descartados:

- Olist_order_reviews_dataset.csv, por contener texto libre y requerir técnicas de procesamiento del lenguaje natural.
- Olist_sellers_dataset.csv, para evitar una dimensión adicional que incrementaría la complejidad sin aportar valor significativo al análisis principal.
- Olist_geolocation_dataset.csv, debido a su elevada granularidad y volumen de datos.

Esta selección permite construir un modelo de Business Intelligence completo sin sobrepasar el alcance previsto para el proyecto.

4.Descripción de los CSV utilizados.

En esta sección se describe de forma detallada el contenido de cada uno de los ficheros CSV utilizados en el proyecto, incluyendo todas sus columnas. Esta descripción resulta fundamental para comprender las decisiones posteriores de modelado y las transformaciones realizadas durante el proceso ETL.

4.1 olist_orders_dataset.csv

Este fichero contiene la información general de los pedidos realizados en la plataforma de comercio electrónico, así como las distintas fechas asociadas a su ciclo de vida.

Columnas:

- Order_id: identificador único del pedido.
- customer_id: identificador del cliente en el sistema origen asociado al pedido.
- order_status: estado actual del pedido (por ejemplo, *created*, *approved*, *shipped*, *delivered*, *canceled*).
- order_purchase_timestamp: fecha y hora en la que el pedido fue realizado.
- order_approved_at: fecha y hora en la que el pedido fue aprobado por el sistema.
- order_delivered_carrier_date: fecha y hora en la que el pedido fue entregado al transportista.
- order_delivered_customer_date: fecha y hora en la que el pedido fue entregado al cliente.
- order_estimated_delivery_date: fecha estimada de entrega calculada por el sistema.

Este fichero proporciona la base temporal y operativa para el análisis de ventas.

4.2 olist_order_items_dataset.csv

Este fichero describe las líneas de pedido, es decir, los productos incluidos en cada pedido. Define la granularidad del hecho principal de ventas.

Columnas:

- `order_id`: identificador del pedido al que pertenece la línea.
- `order_item_id`: número de línea dentro del pedido, que permite distinguir múltiples productos en un mismo pedido.
- `product_id`: identificador del producto vendido.
- `seller_id`: identificador del vendedor que suministra el producto.
- `shipping_limit_date`: fecha límite para el envío del producto.
- `price`: precio del producto en la línea de pedido.
- `freight_value`: coste de envío asociado a la línea de pedido.

4.3 `olist_customers_dataset.csv`

Este fichero describe las líneas de pedido, es decir, los productos incluidos en cada pedido. Define la granularidad del hecho principal de ventas.

Columnas:

- `order_id`: identificador del pedido al que pertenece la línea.
- `order_item_id`: número de línea dentro del pedido, que permite distinguir múltiples productos en un mismo pedido.
- `product_id`: identificador del producto vendido.
- `seller_id`: identificador del vendedor que suministra el producto.
- `shipping_limit_date`: fecha límite para el envío del producto.
- `price`: precio del producto en la línea de pedido.
- `freight_value`: coste de envío asociado a la línea de pedido.

4.4 `olist_products_dataset.csv`

Este fichero contiene la información de los clientes de la plataforma, incluyendo datos geográficos.

Columnas:

- `customer_id`: identificador operativo del cliente en el sistema origen, utilizado para relacionar pedidos y clientes.
- `customer_unique_id`: identificador del cliente real, independiente del número de pedidos realizados.
- `customer_zip_code_prefix`: prefijo del código postal del cliente.

- customer_city: ciudad de residencia del cliente.
- customer_state: estado o región del cliente.

Este fichero se utiliza para construir la dimensión cliente del Data Warehouse.

4.5 olist_order_payments_dataset.csv

Este fichero recoge la información descriptiva de los productos disponibles en el catálogo.

Columnas:

- product_id: identificador único del producto.
- product_category_name: nombre de la categoría del producto.
- product_name_length: longitud del nombre del producto.
- product_description_length: longitud de la descripción del producto.
- product_photos_qty: número de fotografías asociadas al producto.
- product_weight_g: peso del producto en gramos.
- product_length_cm: longitud del producto en centímetros.
- product_height_cm: altura del producto en centímetros.
- product_width_cm: anchura del producto en centímetros.

Estos atributos permiten realizar análisis por tipo de producto y características físicas.

4.6 product_category_name_translation.csv

Este fichero proporciona la traducción al inglés de las categorías de producto.

Columnas:

- product_category_name: nombre de la categoría en el idioma original.
- product_category_name_english: traducción al inglés de la categoría.

Este fichero se utiliza para enriquecer la dimensión producto y facilitar la interpretación de los análisis.

4.7 Consideraciones finales sobre los datos.

Aunque no todas las columnas descritas se utilicen inicialmente en los análisis o dashboards, se han conservado en la base de datos con el objetivo de:

- Mantener la trazabilidad con los datos de origen.

- Permitir la ampliación futura del análisis.
- Facilitar la derivación de métricas adicionales durante el proceso ETL.

5. Decisiones generales de diseño.

Durante el diseño del modelo se han adoptado las siguientes decisiones clave:

- Se consideran ventas válidas únicamente aquellos pedidos cuyo `order_status` es `delivered`.
- La fecha principal de análisis es la fecha de compra (`order_purchase_timestamp`), a partir de la cual se deriva la dimensión temporal.
- Se ha definido la granularidad del hecho principal como una línea de pedido (producto dentro de un pedido).
- El modelo se desacopla de los identificadores del sistema origen mediante el uso de claves sustitutas (*surrogate keys*) en todas las dimensiones.
- El diagrama en estrella representa una visión conceptual, mientras que la base de datos física puede incluir atributos adicionales de trazabilidad u operativos.

6. Uso de claves sustitutas (Surrogate Keys)

Aunque el proyecto integra datos procedentes de una única fuente, se ha optado por el uso de claves sustitutas (SK) como claves primarias en las dimensiones.

Esta decisión se justifica por los siguientes motivos:

- Permiten desacoplar el modelo analítico del sistema origen, evitando dependencias directas de los identificadores originales.
- Facilitan la homogeneidad del diseño, empleando el mismo patrón en todas las dimensiones.
- Mejoran la claridad conceptual del Data Warehouse, diferenciando claramente entre identificadores de negocio y claves internas.
- Preparan el modelo para una posible integración futura de nuevas fuentes de datos sin necesidad de rediseñar las relaciones existentes.

Las claves originales del dataset se conservan como atributos de las dimensiones o de las tablas de hechos, manteniendo la trazabilidad con los datos de origen.

7. Dimensiones del modelo

7.1. Dimensión cliente (dim_customer)

Representa al cliente real del sistema. Se utiliza `customer_unique_id` como identificador natural, ya que identifica a la persona independientemente de los pedidos realizados.

Para garantizar independencia respecto al sistema origen y mejorar el rendimiento, se emplea una clave sustituta `customer_sk` como clave primaria.

Atributos principales:

- `customer_sk` (PK)
- `customer_unique_id` (UNIQUE)
- `customer_city`
- `customer_state`
- `customer_zip_code_prefix`

Esta dimensión es fundamental para análisis de segmentación y clustering de clientes.

7.2. Dimensión Producto (dim_product)

Contiene la información descriptiva de los productos vendidos. Se ha optado por integrar la categoría del producto directamente dentro de esta dimensión, dado que cada producto pertenece a una única categoría.

Esta decisión simplifica el modelo dimensional y reduce la complejidad del ETL sin comprometer los objetivos analíticos del proyecto.

Atributos principales:

- `product_sk` (PK)
- `product_id` (UNIQUE)
- `product_category_name`
- `product_category_name_english`
- Atributos físicos del producto (peso, dimensiones, número de fotos, etc.)

7.3. Dimensión Fecha (dim_date)

Dimensión temporal generada durante el proceso ETL. Su granularidad es diaria y permite realizar análisis temporales y comparativas entre periodos.

Atributos principales:

- date_sk (PK)
- full_date
- day
- month
- year
- quarter
- week_of_year

8. Tabla de hechos

8.1 Hecho principal de ventas (fact_sales)

Es la tabla central del modelo y recoge las métricas de ventas a nivel de línea de pedido.

Granularidad:

1 fila = 1 producto dentro de un pedido.

Claves:

- fact_sales_id (PK)
- customer_sk (FK)
- product_sk (FK)
- date_sk (FK)

Atributos de trazabilidad y contexto:

- order_id
- order_item_id
- seller_id
- order_status

Métricas:

- price
- freight_value

El atributo `order_item_id` se conserva para garantizar la correcta identificación de cada línea de pedido y mantener la trazabilidad con el dataset original.

8.2 Hecho secundario de pagos (fact_payment)

La información relativa a los pagos se ha modelado como una tabla de hechos independiente, dado que un pedido puede estar asociado a uno o varios pagos.

Granularidad:

1 fila = 1 registro de pago.

Claves:

- `fact_payment_id` (PK)
- `date_sk` (FK)

Atributos:

- `order_id`
- `payment_sequential`
- `payment_type`
- `payment_installments`

Métrica:

- `payment_value`

No se establecen relaciones directas entre tablas de hechos, manteniendo así la coherencia del modelo dimensional.

9.Relaciones del modelo

El modelo sigue un esquema en estrella clásico, donde las tablas de hechos se relacionan mediante relaciones 1:N no identificantes con sus dimensiones correspondientes:

- `fact_sales` se relaciona con `dim_customer`, `dim_product` y `dim_date`.
- `fact_payment` se relaciona únicamente con `dim_date`.

10.Conclusión

El modelo dimensional diseñado proporciona una base sólida para la implementación del Data Warehouse, permitiendo el análisis de ventas, clientes y pagos de forma eficiente. Las decisiones adoptadas priorizan la claridad del modelo, la coherencia analítica y la viabilidad del proyecto, sentando las bases

para el desarrollo posterior de los procesos ETL, los dashboards y las técnicas de Data Science.

11. Diagrama en estrella.

Te adjunto el primer boceto del diagrama en estrella para plantearte un par de preguntas.

