

Predicción de la satisfacción del cliente

Con el objetivo de incorporar técnicas de Data Science al proyecto, se ha planteado un modelo predicción de la satisfacción del cliente. Para ello, se ha utilizado como variable objetivo la valoración media del cliente (`avg_review`), mientras que como variables explicativas se han considerado el número de pedidos, el gasto total, el coste medio de envío y el retraso en la entrega.

En primer lugar, se ha implementado un modelo de regresión lineal, por tratarse de una técnica sencilla e interpretable que permite analizar la relación entre las variables. El modelo ha sido entrenado utilizando un conjunto de datos de entrenamiento (80%) y evaluado sobre un conjunto de prueba (20%), empleando como métricas el error absoluto medio (MAE) y el coeficiente de determinación (R^2).

Los resultados obtenidos muestran un valor de MAE cercano a 1, lo que indica que el modelo presenta un error medio de aproximadamente un punto en la escala de satisfacción. Asimismo, el valor de R^2 obtenido es bajo (en torno a 0,09), lo que sugiere una capacidad limitada del modelo para explicar la variabilidad de la satisfacción del cliente.

No obstante, el análisis de los coeficientes del modelo permite extraer conclusiones relevantes. En particular, se observa que el retraso en la entrega (`avg_delay`) es la variable con mayor impacto negativo sobre la satisfacción, mientras que el coste de envío también presenta una influencia negativa, aunque menor. Por el contrario, el número de pedidos muestra una relación positiva con la satisfacción, indicando que los clientes más recurrentes tienden a estar ligeramente más satisfechos. Finalmente, el gasto total no presenta una influencia significativa.

Con el fin de mejorar la capacidad predictiva, se ha implementado adicionalmente un modelo de Random Forest Regressor, que permite capturar relaciones no lineales entre las variables. En este caso, se observa una mejora en el error medio (MAE), lo que indica una mayor precisión en la predicción de valores individuales. Sin embargo, el valor de R^2 es inferior al obtenido en la regresión lineal, lo que sugiere una menor capacidad explicativa global.

El análisis de la importancia de variables en el modelo Random Forest confirma que el retraso en la entrega es el factor más relevante en la predicción de la satisfacción, seguido del gasto total y del coste de envío. Por el contrario, el número de pedidos presenta una contribución prácticamente nula.

En conjunto, los resultados evidencian que la satisfacción del cliente es una variable compleja, influida por múltiples factores no incluidos en el modelo, como la calidad del producto o la experiencia de compra. No obstante, se confirma que los factores operativos, especialmente el retraso en la entrega, tienen un impacto significativo en la percepción del cliente.

```
=== COMPARATIVA DE MODELOS ===
Regresión Lineal -> MAE: 1.0137 | R2: 0.0935
Random Forest    -> MAE: 0.9813 | R2: 0.0771

=== COEFICIENTES REGRESIÓN LINEAL ===
  Variable  Coeficiente
num_orders    0.049629
total_spent   -0.000192
avg_freight   -0.003369
avg_delay     -0.039883

Intercepto: 3.6517

=== IMPORTANCIA DE VARIABLES RANDOM FOREST ===
  Variable  Importancia
avg_delay   0.355142
total_spent 0.328139
avg_freight 0.310611
num_orders  0.006108
```